UNIVERSIDAD SANTO TOMAS
PRIMER CLAUSTRO UNIVERSITARIO DE COLOMBIA

Facultad de Estadística
Maestría en Ciencia de Datos
Anteproyecto de trabajo de grado
Octubre 2026

Evaluación de la eficiencia técnica y predicción de riesgos en la ejecución del Plan Distrital de Desarrollo 2024-2027 "Bogotá Camina Segura" mediante Análisis Envolvente de Datos (DEA) y Procesamiento de Lenguaje Natural (NLP).

Evaluation of technical efficiency and risk prediction in the execution of the 2024-2027 District Development Plan "Bogotá Walks Safe" using Data Envelopment Analysis (DEA) and Natural Language Processing (NLP).

Jhonatan Smith Doncel Murillo.[a]
jhonatanmurillo.don@usantotomas.edu.co

Jorge Emmanuel Marin Linares.[b]
jorge.linaresmar@usantotomas.edu.co

Adrian Felipe Grateron Ramirez.[c]
adrianramirez.gra@usantotomas.edu.co

Carlos Isaac Zainea Maya.[d]
carloszainea@usantotomas.edu.co

Resumen

El seguimiento al Plan Distrital de Desarrollo (PDD) de Bogotá exige revisar, en un mismo análisis, la ejecución de los recursos, el avance físico de las metas y las explicaciones que acompañan su cumplimiento. En la práctica, esta información se encuentra distribuida entre bases estructuradas y reportes narrativos, lo que dificulta su lectura conjunta. Este anteproyecto plantea integrar dichas fuentes para estudiar la eficiencia técnica de grupos comparables de metas-producto y, posteriormente, explorar la identificación anticipada de casos con riesgo de subejecución física. El estudio tendrá un diseño no experimental, retrospectivo, longitudinal y analítico-predictivo. Se propone utilizar Análisis Envolvente de Datos (DEA) para la medición de eficiencia, técnicas de Procesamiento de Lenguaje Natural (NLP) para organizar información relevante de los reportes y modelos de clasificación con validación temporal. Como resultado se espera formular un procedimiento reproducible que sirva de apoyo al seguimiento institucional y a la priorización de metas que requieran una revisión más detallada.

Palabras clave: eficiencia técnica, gasto público, DEA, NLP, aprendizaje automático, alertas tempranas, Plan Distrital de Desarrollo.

[a]Jhonatan Smith Doncel Murillo
[b]Jorge Emmanuel Marin Linares
[c]Adrian Felipe Grateron Ramirez
[d]Carlos Isaac Zainea Maya

1. Introducción

La Veeduría Distrital es el organismo de vigilancia y control preventivo del Distrito Capital y, de acuerdo con las funciones previstas en el Decreto Ley 1421 de 1993 y el Acuerdo Distrital 24 de 1993, hace seguimiento a la gestión de la Administración Distrital para advertir riesgos y aportar al mejoramiento de la gestión pública. Dentro de este trabajo se encuentra el seguimiento preventivo al Plan Distrital de Desarrollo 2024–2027 «Bogotá Camina Segura», que reúne los objetivos, programas, metas e inversiones que orientan la acción del Distrito durante el periodo de gobierno. Para revisar su avance se consultan distintas fuentes institucionales, entre ellas SEGPLAN, administrado por la Secretaría Distrital de Planeación, donde se registra información sobre programación, ejecución y cumplimiento de metas. Por tanto, el seguimiento no se reduce a verificar cuánto presupuesto se ha ejecutado, sino que también requiere observar qué se había programado, qué avance físico se reporta y cómo se relacionan ambos componentes en cada corte.

Esta lectura conjunta es necesaria porque el comportamiento de una meta no siempre puede interpretarse a partir de un solo indicador. Una ejecución financiera alta puede coexistir con un avance físico menor al esperado y, en sentido contrario, un porcentaje bajo de cumplimiento en un momento específico puede obedecer a la programación prevista para la vigencia y no necesariamente a una dificultad de gestión. Además, parte de las razones que explican estas diferencias no aparece en las bases numéricas, sino en informes y reportes en formato PDF donde se consignan retrasos, dificultades operativas, procesos contractuales, dependencias administrativas u otros hechos que afectan la ejecución. En consecuencia, el problema de análisis no radica únicamente en disponer de información, sino en poder relacionar fuentes que tienen estructuras y niveles de detalle diferentes, de modo que sea posible distinguir entre un comportamiento esperado y una situación que amerite seguimiento adicional.

Con base en esta necesidad, el anteproyecto propone construir un esquema analítico que articule la ejecución financiera, el avance físico y la información contenida en los reportes institucionales. La primera parte del análisis se apoyará en Análisis Envolvente de Datos (DEA) para estimar eficiencia relativa únicamente entre metas que puedan considerarse comparables; paralelamente, se utilizarán técnicas de Procesamiento de Lenguaje Natural (NLP) para organizar y extraer información relevante de los textos. Una vez integrados estos componentes, se explorará un modelo de clasificación que permita reconocer patrones asociados con un posible riesgo de subejecución física. La intención es que cada técnica responda a una parte concreta del problema: DEA permitirá estudiar la relación entre recursos y resultados, mientras que NLP aportará elementos de contexto que los indicadores cuantitativos no recogen por sí solos y el componente predictivo evaluará si esa información conjunta puede ser útil para anticipar casos que requieran revisión.

La propuesta se concibe como un apoyo al seguimiento preventivo y no como un sustituto de los instrumentos institucionales ni del criterio técnico de quienes analizan las metas. En ese sentido, los puntajes de eficiencia, las categorías obtenidas de los textos y las probabilidades de riesgo se interpretarán como señales para ordenar y priorizar la revisión, no como conclusiones automáticas sobre el desempeño de una entidad. Su alcance dependerá, además, de la calidad y periodicidad de las fuentes, de la posibilidad de comparar las metas y de la trazabilidad entre los diferentes cortes de información. Bajo estas condiciones, el aporte del proyecto estará en organizar fuentes que hoy se revisan por separado y en evaluar si su integración permite hacer un seguimiento más consistente y oportuno.

La pregunta que orienta el estudio es:

¿De qué manera la integración de la medición de eficiencia técnica y el análisis de la información cualitativa permite evaluar la eficiencia y clasificar anticipadamente las metas--producto y actividades según su nivel de riesgo de subejecución física en el Plan de Desarrollo Distrital de Bogotá?

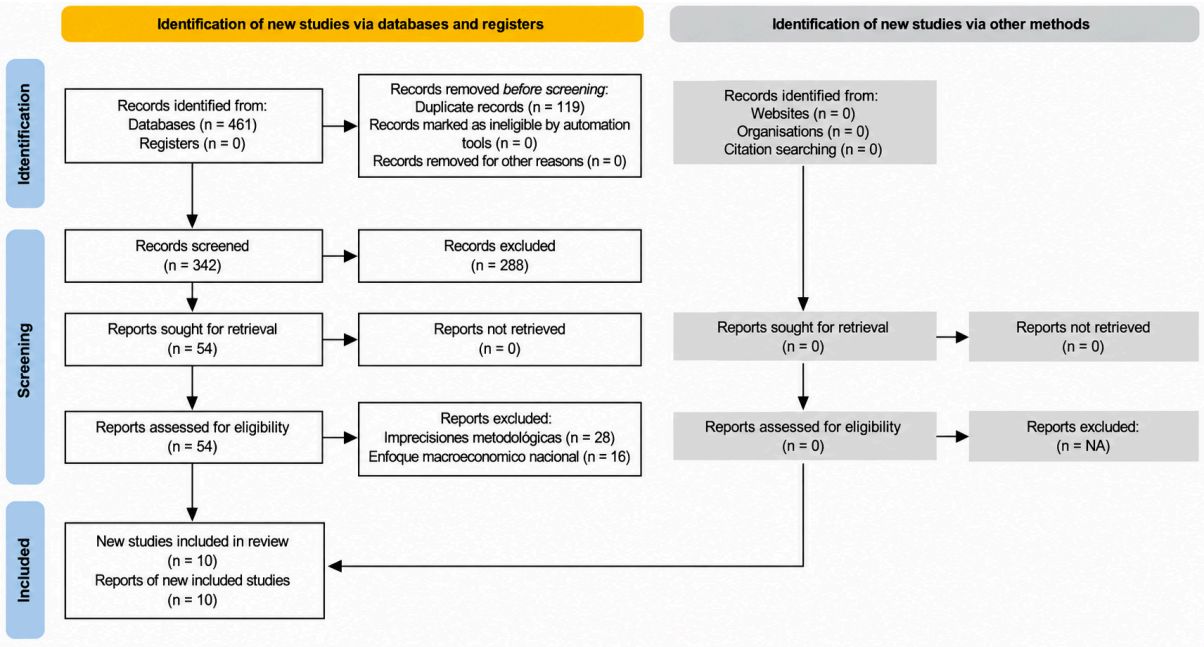
La pregunta reúne tres componentes que se desarrollarán de manera encadenada: primero se estimará la eficiencia relativa entre metas que sean comparables; después se examinarán las barreras de ejecución presentes en los reportes narrativos y, finalmente, se evaluará si la información disponible hasta cada corte permite anticipar situaciones de riesgo mediante un modelo de clasificación.

2. Marco teórico y revisión de literatura

2.1. Antecedentes de investigación

Durante la formulación del anteproyecto se revisó literatura sobre cuatro temas que convergen en el problema planteado: seguimiento de planes territoriales, eficiencia del gasto público, tratamiento de información no estructurada y predicción de riesgos en proyectos. La búsqueda se organizó tomando como referencia PRISMA 2020 y se construyeron nueve ecuaciones con términos relacionados con evaluación de planes de desarrollo, eficiencia técnica, analítica predictiva, minería de datos y gestión pública. El propósito de esta revisión no fue validar anticipadamente la solución propuesta, sino reconocer qué métodos se han utilizado en problemas semejantes y qué limitaciones deben considerarse antes de trasladarlos al contexto del PDD de Bogotá.

Diagrama de flujo PRISMA 2020 para la selección de la literatura



Nota. Elaboración propia a partir del proceso de búsqueda y selección de literatura.

La búsqueda inicial arrojó 67.884 registros, por lo que fue necesario aplicar filtros de periodo de publicación, idioma y revisión por pares antes de iniciar la lectura. Con estos criterios el conjunto se redujo a 461 documentos; posteriormente se eliminaron 119 duplicados y se examinaron los títulos y resúmenes de 342 publicaciones. De estas, 288 se descartaron porque no guardaban una relación suficiente con el problema de investigación. Los 54 documentos restantes se revisaron a texto completo y, después de valorar su pertinencia y su aporte metodológico, se seleccionaron 10 investigaciones para conformar la Matriz Q que sirve de base a los antecedentes del proyecto.

Los diez trabajos seleccionados pueden organizarse en cuatro líneas. La primera se relaciona con el **seguimiento territorial y la ejecución del gasto público**. Rozo Contreras (2020), Marinas y Prioteasa (2015), Franco Vargas et al. (2019) y Arteaga Huarancca y Mayuri Carlos (2026), aunque estudian contextos distintos, muestran una dificultad común: la ejecución presupuestal aislada no explica por completo el desempeño de una intervención pública. Sus resultados llevan a considerar también la programación, el avance físico, la capacidad institucional y las condiciones que están detrás de retrasos o desviaciones.

La segunda línea corresponde a la **medición de eficiencia y desempeño público**. Eroğlu y Taştan (2025) y Benvenuto et al. (2025) utilizan DEA para comparar gobiernos locales y encuentran que mayores niveles de gasto no se traducen necesariamente en mejores resultados. A esta discusión se suma Boykin et al. (2025), quienes advierten que la medición de eficiencia y efectividad cambia según el tipo de unidad y el contexto en el que opera. Para este anteproyecto, estos hallazgos son relevantes porque indican que no sería metodológicamente adecuado comparar todas las metas-producto bajo una única frontera; antes de estimar eficiencia será necesario establecer grupos con condiciones razonables de homogeneidad.

La tercera línea aborda el **aprovechamiento de datos abiertos e información no estructurada**. Sánchez-Chero et al. (2026) revisan técnicas de extracción y estructuración de datos públicos, mientras

que Monsalvo et al. (2025) analizan información narrativa en un contexto de control fiscal preventivo. Ambos antecedentes resultan útiles porque muestran que los textos institucionales pueden dejar de tratarse únicamente como material de lectura y convertirse, con un proceso documentado de extracción y codificación, en información que pueda relacionarse con variables de desempeño.

La cuarta línea corresponde a la **analítica predictiva aplicada al desempeño de proyectos**. Ojiako et al. (2026) muestran que la información histórica puede utilizarse para construir modelos orientados a anticipar resultados de proyectos. Este antecedente aporta criterios para el componente predictivo, aunque su traslado al PDD requiere ajustes importantes: la variable objetivo debe responder a la periodicidad real de los cortes, la validación debe respetar la secuencia temporal y ninguna variable podrá contener información posterior al momento que se intenta predecir.

En conjunto, los antecedentes ofrecen sustento para los tres componentes metodológicos del proyecto, pero también muestran que suelen estudiarse por separado. La brecha de interés para esta investigación está precisamente en esa separación: por un lado se analiza el uso de los recursos y el avance físico; por otro se revisan las explicaciones narrativas y, en trabajos distintos, se construyen modelos predictivos. El anteproyecto propone evaluar si estos elementos pueden articularse en un mismo esquema de seguimiento para las metas-producto del PDD de Bogotá, conservando la comparabilidad entre unidades y utilizando únicamente la información disponible en cada momento del análisis.

La tabla siguiente resume los diez estudios de la Matriz Q y muestra, para cada uno, qué aspecto del problema ayuda a sustentar y de qué manera se vincula con la propuesta.

Tabla. Síntesis de los antecedentes incluidos en la Matriz Q y su relación con la propuesta de investigación.

Referencia	Enfoque	Aporte para el problema	Relación con la propuesta
Rozo Contreras (2020)	Seguimiento territorial y evaluación de planes de desarrollo	Evalúa el cumplimiento de las metas de un Plan Municipal de Desarrollo mediante indicadores administrativos, programación y avance físico. Evidencia diferencias entre las metas formuladas y las registradas en los sistemas oficiales de seguimiento, así como comportamientos heterogéneos entre sectores.	Constituye un antecedente colombiano directamente relacionado con el seguimiento de planes territoriales. Permite sustentar la necesidad de complementar los indicadores tradicionales de cumplimiento con una medición que relacione recursos financieros, avance físico y evolución de las metas del PDD de Bogotá 2024–2027.
Ojiako et al. (2026)	Machine Learning y predicción del desempeño de proyectos	Desarrolla modelos supervisados para predecir el desempeño de proyectos y muestra la utilidad de combinar modelos de ensamble, calibración probabilística e interpretabilidad para identificar factores asociados con el riesgo.	Aporta un referente metodológico para el componente predictivo del proyecto. Su enfoque permite orientar la comparación de modelos de clasificación y la generación de probabilidades de riesgo, adaptando el problema desde el éxito general de proyectos hacia el riesgo de subejecución de las metas-producto.
Eroğlu & Taştan (2025)	DEA y eficiencia técnica municipal	Evalúa la eficiencia relativa de gobiernos locales mediante modelos DEA y análisis de holguras, mostrando que mayores niveles de gasto no necesariamente se traducen en mejores resultados. También identifica fuentes específicas de exceso de recursos y déficit de productos.	Es uno de los antecedentes metodológicos más próximos al primer objetivo específico. Sustenta el uso de DEA para comparar unidades homogéneas y respalda la necesidad de segmentar previamente las metas-producto antes de construir fronteras de eficiencia.

Referencia	Enfoque	Aporte para el problema	Relación con la propuesta
Benvenuto et al. (2025)	DEA y evaluación del gasto público	Analiza la eficiencia del gasto en ciudades metropolitanas y encuentra diferencias importantes entre unidades administrativas. El estudio muestra que el nivel de gasto, considerado de manera aislada, no permite determinar si una administración utiliza eficientemente sus recursos.	Refuerza la decisión de analizar la eficiencia por grupos o sectores comparables y respalda la construcción de indicadores que relacionen recursos financieros con resultados físicos, en lugar de utilizar exclusivamente porcentajes de ejecución presupuestal.
Boykin et al. (2025)	Medición del desempeño y contratación pública	Demuestra que los indicadores de eficiencia y efectividad cambian según el tipo de entidad, contrato y contexto institucional. Advierte que el uso de indicadores agregados sin considerar estas diferencias puede producir interpretaciones equivocadas sobre el desempeño público.	Aporta fundamento para no comparar de forma indiscriminada todas las metas del PDD. Su planteamiento respalda la segmentación de unidades comparables y el uso de una evaluación multidimensional que incorpore características institucionales y operativas.
Marinas & Prioteasa (2015)	Ejecución presupuestal y capacidad institucional	Identifica que la baja absorción de recursos puede estar asociada con problemas administrativos, retrasos en los procesos de pago y limitaciones de capacidad institucional. Muestra que el análisis financiero retrospectivo no permite reconocer oportunamente todos los factores que afectan la ejecución.	Sustenta la necesidad de analizar conjuntamente ejecución financiera y avance físico. También respalda el interés por identificar de manera anticipada barreras administrativas que puedan afectar el cumplimiento de las metas del Plan Distrital de Desarrollo.
Franco Vargas et al. (2019)	Control social y seguimiento de la administración pública	Evidencia limitaciones en el control social cuando la información pública no se encuentra disponible de manera oportuna, integrada y suficientemente detallada. El estudio señala dificultades para realizar seguimiento continuo a la ejecución de los recursos públicos.	Aporta un antecedente nacional sobre la necesidad de fortalecer los mecanismos de seguimiento y acceso a información. Se relaciona con el propósito del proyecto de producir señales analíticas que puedan apoyar el control preventivo y la priorización de situaciones que requieran revisión.
Sánchez-Chero et al. (2026)	Minería de datos abiertos y gestión pública	Revisa el uso de técnicas de extracción y minería de datos abiertos en administraciones públicas y destaca su utilidad para integrar fuentes heterogéneas, identificar ineficiencias operativas y mejorar la disponibilidad de información para el análisis.	Sustenta la etapa de adquisición, transformación e integración de las fuentes del proyecto. Su aporte resulta especialmente pertinente para estructurar un flujo reproducible que combine información financiera, física y documental proveniente de diferentes formatos.
Arteaga Huarancca & Mayuri Carlos (2026)	Ejecución presupuestal de la inversión pública	La revisión identifica que la subejecución municipal responde a factores como capacidad técnica, rotación institu-	Se relaciona directamente con el problema del anteproyecto porque respalda la necesidad de vincular el gasto

Referencia	Enfoque	Aporte para el problema	Relación con la propuesta
		cional, dificultades de gestión y ausencia de sistemas integrados de seguimiento. También señala las limitaciones de evaluar la ejecución únicamente mediante indicadores financieros lineales.	ejecutado con la oportunidad y el avance físico de las metas. Además, sustenta la conveniencia de avanzar hacia un seguimiento continuo con capacidad de identificar tempranamente situaciones de riesgo.
Monsalvo et al. (2025)	Inteligencia artificial y control fiscal preventivo	Analiza información narrativa de entidades públicas colombianas para evaluar riesgos de control fiscal y encuentra una asociación relevante entre la valoración automatizada de los textos y la evaluación realizada por auditores expertos.	Es el antecedente colombiano más próximo al componente de NLP del proyecto. Demuestra que los reportes cualitativos pueden transformarse en información útil para el análisis preventivo y respalda su integración con indicadores de desempeño para apoyar la identificación y priorización de riesgos.

Nota. Elaboración propia a partir de los estudios incluidos en la Matriz Q.

2.2. Bases teóricas

2.2.1. Eficiencia técnica y evaluación del gasto público

La eficiencia técnica permite analizar la relación entre los recursos utilizados y los resultados alcanzados por una unidad de decisión. En este trabajo no se asumirá que ejecutar una mayor proporción del presupuesto equivale, por sí mismo, a ser más eficiente. Lo que se buscará es establecer si, dentro de grupos de metas comparables, las diferencias en recursos financieros guardan relación con el avance físico u otros productos que puedan medirse de manera consistente. Esta distinción es necesaria porque dos metas con niveles similares de gasto pueden mostrar trayectorias de cumplimiento diferentes.

Aplicar esta idea al PDD exige una precaución adicional: las 425 metas-producto no persiguen los mismos resultados ni operan bajo la misma escala, unidad de medida o programación. Por esta razón, no se plantea construir una única comparación para todo el Plan. Antes de estimar una frontera de eficiencia se revisarán las características de las metas y solo se agruparán aquellas para las que pueda justificarse una lógica de producción semejante.

2.2.2. Análisis Envolvente de Datos (DEA)

Para este trabajo, el interés del Análisis Envolvente de Datos (DEA) está en poder comparar el uso de los recursos con los resultados físicos sin imponer de antemano una forma funcional a esa relación. Cada meta-producto que cumpla las condiciones de comparabilidad se tratará como una unidad de decisión y su desempeño se contrastará con el de otras metas del mismo grupo. La frontera que resulte de esa comparación representará el mejor comportamiento observado dentro del conjunto y, por tanto, el puntaje obtenido deberá entenderse como una medida relativa. No indicará si una entidad es «buena» o «mala», sino qué tan cerca se encuentra una meta de las combinaciones de recursos y resultados que muestran mejor desempeño entre unidades semejantes.

Como referencia inicial se considera el modelo BCC de Banker, Charnes y Cooper (1984), que permite trabajar con rendimientos variables a escala. Esta característica es útil para el problema planteado porque las metas del PDD pueden tener tamaños, presupuestos y alcances distintos incluso dentro de un mismo sector. Sin embargo, la elección final del modelo no se cerrará antes de examinar los datos. Primero será necesario revisar cuántas metas pueden conformar grupos suficientemente homogéneos y qué variables conservan una interpretación comparable entre ellas. A partir de esa revisión se definirá la orientación del modelo y la combinación de insumos y productos que resulte metodológicamente defendible.

En principio, los recursos financieros asignados o ejecutados se evaluarán como posibles insumos, mientras que la programación y el avance físico constituirán la base para definir los productos. Si las fuentes contienen otras medidas con cobertura y unidades consistentes, por ejemplo beneficiarios atendidos, se revisará si su inclusión aporta información sin alterar la comparabilidad del grupo. Este punto es importante porque agregar variables solo por estar disponibles puede reducir la capacidad discriminante

del DEA. Por ello, la especificación final buscará mantener un número de variables acorde con la cantidad de unidades analizadas y con la lógica de cada grupo de metas.

El cronograma incluye también una revisión de la viabilidad del Análisis de Frontera Estocástica (SFA) como contraste. Su aplicación dependerá de que exista un número suficiente de observaciones y de que pueda justificarse una forma funcional para la relación entre insumos y resultados. Si esas condiciones no se cumplen, SFA no se incorporará únicamente para completar una comparación metodológica; en ese caso, el análisis de eficiencia se concentrará en DEA y en pruebas de sensibilidad sobre su especificación.

2.2.3. Procesamiento de Lenguaje Natural (NLP)

Una parte importante de la explicación sobre el avance de las metas no está contenida en las variables numéricas. Los reportes institucionales suelen registrar hechos como retrasos contractuales, ajustes en la programación, dependencia de terceros, dificultades administrativas o cambios en las condiciones de ejecución. Esta información puede ser determinante para interpretar un porcentaje de avance, pero su formato narrativo hace que resulte difícil incorporarla de manera sistemática cuando se revisan muchas metas y varios cortes de seguimiento.

El componente de Procesamiento de Lenguaje Natural se utilizará precisamente para trabajar con esa información. El procedimiento comenzará con la extracción del texto y la identificación de los fragmentos que puedan vincularse con una meta o con un corte específico; después se realizarán tareas de limpieza y normalización que permitan analizar el contenido con criterios homogéneos. A partir del corpus se buscarán categorías relacionadas con barreras o condiciones de ejecución, evitando fijar desde el anteproyecto una clasificación cerrada que después no corresponda con lo que realmente aparece en los documentos.

Una vez obtenidas estas categorías o representaciones, se estudiará su relación con los resultados del componente de eficiencia y con otras variables del seguimiento. El propósito no será reemplazar la lectura de los reportes, sino convertir parte de su contenido en información estructurada que pueda ser consultada, comparada y utilizada en los análisis posteriores. De esta forma, una explicación que hoy aparece únicamente como texto podrá relacionarse con el comportamiento financiero y físico de la misma meta.

2.2.4. Analítica predictiva y alertas tempranas

El componente predictivo se desarrollará después de integrar la información financiera, física y textual. La unidad de observación será la combinación meta–corte y la pregunta operativa será si, con la información disponible hasta un momento determinado, es posible anticipar que la meta tendrá una condición de subejecución física en el corte siguiente. Esta forma de plantear el problema obliga a conservar el orden temporal de los registros y evita utilizar información que todavía no habría estado disponible al momento de generar la alerta.

La variable objetivo se construirá a partir de la relación entre el avance físico programado y el avance observado en el periodo posterior. Su definición exacta se establecerá cuando se revise la periodicidad efectiva de las fuentes y la forma en que cada tipo de meta registra su programación. De la misma manera, no se seleccionará de antemano un algoritmo específico. Se compararán modelos de clasificación apropiados para datos tabulares y la elección tendrá en cuenta no solo su desempeño, sino también su estabilidad y la posibilidad de explicar qué variables están influyendo en las predicciones.

La evaluación se hará mediante una partición temporal de los datos, separando periodos para entrenamiento, validación y prueba sin mezclar información futura con observaciones anteriores. Además, el modelo integrado se contrastará con una línea base construida únicamente con variables financieras. Esta comparación permitirá establecer si los puntajes de eficiencia y la información derivada de los reportes realmente agregan capacidad predictiva o si el resultado puede obtenerse con los indicadores que ya se utilizan en el seguimiento tradicional.

2.2.5. Brecha de investigación e hipótesis

La revisión de literatura muestra antecedentes para analizar eficiencia, estructurar información narrativa y construir modelos predictivos; sin embargo, estos componentes suelen abordarse por separado. En el caso del PDD de Bogotá, el interés está en examinar qué ocurre cuando se conectan dentro de un mismo flujo de seguimiento: primero la relación entre recursos y avance físico, luego las explicaciones contenidas en los reportes y, finalmente, la posibilidad de utilizar ambos tipos de información para anticipar situaciones que requieran revisión.

El aporte esperado, por tanto, no consiste en proponer un nuevo algoritmo DEA ni una técnica inédita de NLP. La contribución se ubica en la integración metodológica y en su adaptación a la estructura real de la información disponible en SEGPLAN. Con esa lógica se plantean las siguientes hipótesis:

Hipótesis central (H1). Un modelo que incorpore de manera conjunta variables financieras y físicas, resultados de eficiencia técnica y características obtenidas de los reportes narrativos tendrá mayor capacidad para identificar tempranamente metas-producto con riesgo de subejecución física que una línea base basada solo en ejecución financiera.

Hipótesis nula (H0). La incorporación de los resultados DEA y de las variables obtenidas mediante NLP no producirá una mejora estadísticamente verificable frente a una línea base construida únicamente con información financiera.

Hipótesis auxiliar 1. Dentro de grupos de metas comparables existirán diferencias en eficiencia técnica relativa que no podrán explicarse únicamente por el porcentaje de ejecución presupuestal.

Hipótesis auxiliar 2. Las brechas de eficiencia estarán asociadas con características de la ejecución física y financiera y con patrones de barreras identificados en los reportes institucionales.

3. Objetivos

3.1. Objetivo general

Diseñar y evaluar un esquema analítico para el seguimiento de las metas-producto del Plan Distrital de Desarrollo de Bogotá 2024–2027, integrando información financiera y física de SEGPLAN, medición de eficiencia técnica mediante Análisis Envolvente de Datos (DEA) y variables obtenidas de reportes no estructurados mediante Procesamiento de Lenguaje Natural (NLP), con el fin de explorar la identificación anticipada de riesgos de subejecución física.

3.2. Objetivos específicos

a. **Medición de eficiencia (DEA):** Estimar la eficiencia técnica relativa de metas-producto que puedan agruparse bajo criterios de comparabilidad, relacionando los recursos financieros utilizados con el avance físico registrado en los cortes de seguimiento.
b. **Análisis de información narrativa (NLP):** Identificar y estructurar barreras operativas o de gestión presentes en los reportes institucionales y analizar su relación con las brechas de eficiencia observadas.
c. **Componente predictivo:** Construir y evaluar un modelo de clasificación que utilice la información disponible hasta cada corte para estimar el riesgo de subejecución física en el periodo siguiente y comparar su desempeño con una línea base basada únicamente en indicadores financieros.

4. Metodología

La estrategia metodológica sigue el orden en que se produce y puede utilizarse la información del seguimiento. Primero se revisará la calidad y comparabilidad de las fuentes; después se desarrollarán los componentes de eficiencia y análisis de texto, y solo cuando estos resultados puedan vincularse por meta y corte se construirá el conjunto de datos para la fase predictiva. Esta secuencia permite que las decisiones metodológicas dependan de lo que realmente soportan los datos y evita definir desde el anteproyecto especificaciones que todavía no pueden comprobarse.

a. **Paradigma y diseño de investigación**

   El estudio se plantea desde un **paradigma pragmático** porque parte de una necesidad concreta de seguimiento de la gestión pública y combina métodos distintos en función de la pregunta de investigación. El componente principal será cuantitativo, pero incluirá el procesamiento computacional de información narrativa para incorporar elementos que no están disponibles en las bases estructuradas.

   El diseño será **no experimental** porque no se intervendrá sobre la asignación de recursos ni sobre la ejecución de las metas; **retrospectivo** porque utilizará información administrativa ya producida; y **longitudinal** porque seguirá el comportamiento de las metas a través de distintos cortes. Además, tendrá un componente **analítico-predictivo**, ya que primero se estudiarán relaciones y medidas de eficiencia y posteriormente se evaluará si esas variables ayudan a anticipar una condición futura de subejecución.

   El uso de NLP no convierte el estudio en una investigación cualitativa tradicional. Los textos funcionarán como una fuente adicional de datos y serán transformados en categorías o representaciones que puedan enlazarse con la información cuantitativa de cada meta.

b. **Población, unidades de análisis y criterios de inclusión**

   El marco de referencia está compuesto por las **425 metas-producto del Plan Distrital de Desarrollo de Bogotá 2024–2027** registradas en las fuentes oficiales de seguimiento. No obstante,

el número de observaciones será diferente para cada componente del proyecto, porque DEA, NLP y el modelo predictivo requieren condiciones de información distintas.

Para DEA se trabajará solo con metas que tengan información suficiente y que puedan ubicarse en grupos con una lógica de comparación común. Esto implica que una meta puede pertenecer al universo del PDD y, aun así, quedar por fuera del análisis de eficiencia si no existe otra unidad comparable o si carece de las variables mínimas. En NLP se incluirán los reportes que puedan relacionarse de manera trazable con las metas seleccionadas. Para la predicción, la observación será el registro **meta–corte**, de modo que las variables explicativas correspondan a un momento y la condición de riesgo pueda observarse después.

Se excluirán registros sin identificador confiable, duplicados que no puedan resolverse y cortes que no contengan la información mínima necesaria. En DEA también se excluirán las metas para las que no sea posible justificar un grupo homogéneo de comparación.

c. **Variables de análisis y operacionalización**

Variable / dimensión	**Naturaleza**	**Indicador preliminar**	**Uso analítico**
Recursos financieros	Cuantitativa	Asignado, comprometido/ejecutado, porcentaje de ejecución	Insumo candidato en DEA y predictor de contexto.
Avance físico	Cuantitativa	Programación, avance observado, porcentaje de cumplimiento	Producto candidato en DEA y referencia para definir la condición futura de riesgo.
Eficiencia técnica	Derivada	Puntaje DEA y distancia relativa frente a la frontera	Resultado del primer objetivo y variable potencial para el componente predictivo.
Barreras operativas	Derivada de texto	Categorías, presencia, frecuencia o representación textual	Resultado del segundo objetivo y conjunto de variables explicativas.
Características institucionales	Categóricas / temporales	Sector, entidad, programa, vigencia y corte	Definición de grupos comparables, controles y descripción del contexto.
Riesgo de subejecución	Variable objetivo	Diferencia entre avance físico programado y observado en el horizonte definido $(t+1)$	Variable de respuesta del modelo de clasificación.

Tabla 1: Variables preliminares y función prevista dentro del análisis.

d. **Fuentes, preparación e integración de la información**

Las fuentes principales serán **Avance del Plan de Desarrollo**, **Gestión e Inversión** y los reportes institucionales asociados a SEGPLAN. Antes de unirlas se elaborará un inventario de variables y cortes para identificar qué contiene cada fuente, con qué periodicidad se actualiza y a qué nivel está desagregada. Esta revisión será necesaria porque un mismo concepto puede aparecer con nombres, formatos o unidades diferentes según el archivo de origen.

La preparación incluirá la homologación de identificadores, estandarización de fechas y porcentajes, revisión de duplicados, análisis de valores faltantes y controles de consistencia entre cortes. Los documentos narrativos se vincularán con las metas mediante los identificadores y metadatos disponibles. Cada transformación quedará registrada dentro del flujo ELT para mantener trazabilidad entre el archivo original y la tabla utilizada en el análisis.

e. **Plan de análisis**

La primera etapa será exploratoria. Se revisará la cobertura de las variables por meta y por corte, se identificarán cambios de estructura entre periodos y se describirán las diferencias de escala entre metas. Con esta información se definirán los grupos que podrán pasar al análisis de eficiencia y se determinará qué registros cuentan con continuidad temporal suficiente para el componente predictivo.

En la segunda etapa se estimará la eficiencia mediante DEA dentro de los grupos previamente definidos. La orientación del modelo, los rendimientos a escala y las variables incluidas se justificarán para cada especificación. Además de los puntajes se revisarán las holguras y la sensibilidad de los resultados frente a cambios razonables en la selección de insumos y productos. La posible aplicación

de SFA se decidirá después de evaluar si existe suficiente información para especificar y estimar una frontera paramétrica de manera consistente.

La tercera etapa se concentrará en los reportes narrativos. Una vez extraído y normalizado el texto, se identificarán expresiones y categorías relacionadas con condiciones que puedan afectar la ejecución. El resultado de esta fase deberá poder vincularse con una meta y un corte concreto; de lo contrario, la información se conservará como contexto descriptivo pero no se utilizará como predictor.

Después se estudiará la asociación entre las barreras identificadas y las diferencias de eficiencia observadas. Las pruebas o modelos estadísticos se escogerán según el tipo y distribución de las variables disponibles. El objetivo de este paso será reconocer relaciones consistentes que ayuden a interpretar los resultados, sin atribuirles un sentido causal que el diseño del estudio no permite establecer.

Por último, se construirá el conjunto meta–corte para el componente predictivo. Las variables de un periodo t se utilizarán para anticipar la condición de subejecución en $t+1$. El conjunto se dividirá respetando el orden cronológico y se compararán diferentes clasificadores. El modelo integrado se evaluará frente a una línea base compuesta solo por indicadores financieros, de manera que pueda medirse el aporte adicional de los componentes DEA y NLP.

f. **Criterios de evaluación y control metodológico**

La revisión del componente DEA no se limitará al valor del puntaje. También se comprobará si la clasificación de las unidades cambia de forma importante al modificar razonablemente los insumos, productos o supuestos del modelo. Si una frontera resulta demasiado sensible o agrupa metas con lógicas distintas, sus resultados no se utilizarán para sacar conclusiones comparativas.

Para NLP se documentará cómo se obtienen las categorías o representaciones y se conservarán ejemplos de los fragmentos que sustentan su interpretación. En el modelo predictivo se controlarán especialmente el desbalance entre clases y la fuga de información temporal. Las métricas principales serán PR-AUC, F1-Score y sensibilidad (Recall); la exactitud global se reportará como referencia cuando sea pertinente, pero no será suficiente para seleccionar el modelo si los casos de riesgo son poco frecuentes.

Finalmente, los resultados se interpretarán como apoyo para el seguimiento. Un puntaje DEA bajo o una probabilidad alta de riesgo señalarán un caso que merece revisión, pero no constituirán por sí mismos evidencia de irregularidad, incumplimiento o responsabilidad institucional.

g. **Coherencia entre objetivos, métodos y productos esperados**

Objetivo	**Información principal**	**Método**	**Producto esperado**
Específico 1	Recursos financieros y avance físico	EDA, conformación de grupos y DEA	Puntajes y brechas de eficiencia relativa para metas comparables.
Específico 2	Reportes narrativos PDF/Excel	Extracción de texto, NLP y análisis de asociación	Categorías de barreras vinculadas con metas y cortes de seguimiento.
Específico 3	Panel integrado meta–corte	Clasificación supervisada y validación temporal a $t+1$	Probabilidad de riesgo y comparación con la línea base financiera.
Objetivo general	Resultados integrados de los tres componentes	Evaluación conjunta	Esquema reproducible de apoyo a la priorización del seguimiento.

Tabla 2: Relación entre objetivos, información, métodos y productos esperados.

5. Cronograma y actividades

El cronograma organiza las actividades entre octubre de 2026 y abril de 2027 siguiendo la dependencia entre los componentes del proyecto. La preparación de las fuentes y la revisión de comparabilidad se ubican al inicio porque de ellas depende qué metas podrán utilizarse en DEA y qué registros tendrán continuidad suficiente para las etapas posteriores. El procesamiento de los reportes se desarrolla en paralelo durante las primeras fases, de manera que sus resultados puedan incorporarse cuando se construya el panel meta–corte.

La fase predictiva comenzará una vez estén disponibles los resultados de eficiencia y las variables derivadas de los textos. Posteriormente se realizará la validación, la comparación con la línea base y

la consolidación de los productos del proyecto. Las actividades asociadas con SFA y con la validación del prototipo se mantienen como tareas condicionadas: la primera solo procederá si la estructura de los datos admite una estimación paramétrica razonable, mientras que la segunda corresponde a una meta de validación prevista y no a un nivel de madurez alcanzado de antemano.

Cronograma de trabajo del proyecto

PLANTILLA DE CRONOGRAMA DEL PROYECTO																													
Objetivo	Fase	Código	Actividad	Responsable	Inicio	Fin	Duración	Hito	Crítica	Sem 1	Sem 2	Sem 3	Sem 4	Sem 5	Sem 6	Sem 7	Sem 18	Sem 19	Sem 20	Sem 21	Sem 22	Sem 23	Sem 24	Sem 25	Sem 26	Sem 27	Sem 28
Específico 1: Estimar el grado de eficiencia técnica de las metas-producto aplicando DEA.	1. Preparación y Medición de Eficiencia	A1.1	Recopilación de información financiera y avance físico del PDD 2024-2028.	Adrian Grateron	1/10/2026	14/10/2026	2	No	No	x	x																
		A1.2	Implementación del flujo ELT y Depuración Estructurada (arquitectura de datos en Databricks/PySpark).	Adrian Grateron	15/10/2026	28/10/2026	2	No	No			x	x														
		A1.3	Análisis Exploratorio de Datos (EDA) y revisión de comparabilidad.	Adrian Grateron	29/10/2026	4/11/2026	1	No	No					x													
		A1.4	Segmentación de las metas-producto para conformar la Unidad de Toma de Decisiones (DMU).	Adrian Grateron	29/10/2026	4/11/2026	1	No	No					x													
		A1.5	Aplicación de las metodologías DEA y SFA para evaluar las fronteras de eficiencia técnica.	Adrian Grateron	5/11/2026	11/11/2026	1	No	Sí						x												
Específico 2: Extraer e identificar barreras operativas en reportes mediante NLP y asociarlas a brechas de eficiencia	2. Procesamiento de Texto y Análisis Cualitativo	A2.1	Extracción y normalización de textos cualitativos de reportes (PDF/Excel).	Jhonatan Doncel	1/10/2026	14/10/2026	2	No	No	x	x																
		A2.2	Aplicación de técnicas NLP para identificar barreras operativas o retrasos estructurales.	Jhonatan Doncel	15/10/2026	28/10/2026	2	No	Sí			x	x														
		A2.3	Asociación estadística de los problemas detectados en texto con las brechas de eficiencia DEA y SFA.	Jhonatan Doncel	12/11/2026	14/11/2026	0.5	Sí	No							x											
Específico 3: Desarrollar un modelo predictivo para clasificar riesgos de subejecución y generar alertas.	3. Modelado Predictivo y Sistema de Alertas	A3.1	Integración de resultados DEA, SFA y NLP con la información del SEGPLAN (corte 2026).	Jhonatan Doncel	3/2/2027	9/2/2027	1	No	No								x										
		A3.2	Entrenamiento del modelo algorítmico y de clasificación (ej. ensambles ML).	Jorge Marin	10/2/2027	2/3/2027	3	No	Sí									x	x	x	x						
		A3.3	Validación del sistema en un entorno de pruebas mediante partición temporal para evitar data leakage (nivel de madurez TRL 4).	Jorge Marin	3/3/2027	16/3/2027	2	No	No												x	x	x				
		A3.4	Diseñar e implementar la arquitectura del tablero de control interactivo (ej. Streamlit/Gradio/PowerBI) para la visualización de predicciones e ineficiencias.	Adrian Grateron, Jorge Marin	3/3/2027	9/3/2027	1	Sí	No												x	x					
		A3.5	Integración y despliegue del sistema de visualización de alertas con los resultados de clasificación del modelo predictivo.	Adrian Grateron, Jorge Marin	17/3/2027	23/3/2027	1	Sí	Sí														x	x			
General: Evaluar eficiencia técnica y predecir riesgos integrando DEA y NLP.	4. Consolidación y Evaluación General	A4.1	Evaluación del desempeño del modelo propuesto	Jorge Marin	24/3/2027	30/3/2027	1	No	Sí															x	x		
		A4.2	Redacción de recomendaciones y formulación del proyecto para entidades decisorias.	Adrian Grateron, Jhonatan Doncel, Jorge Marin	31/3/2027	13/4/2027	2	Sí	No																	x	x	x
Indicaciones										RECESO INTERSEMESTRAL: 15/11/2026 – 02/02/2027																		

Nota. Cronograma elaborado por el equipo para las fases de preparación, análisis de texto, modelado predictivo y consolidación.

6. Presupuesto de Infraestructura Cloud

Para la etapa de integración y consulta de los resultados se contempla una base de datos en la nube destinada a almacenar las tablas de la capa **Gold**. La estimación se incluye como referencia de infraestructura para seis meses de trabajo y no como un costo definitivo. El servicio podrá ajustarse durante la ejecución según el volumen de información consolidado, la frecuencia de actualización y la herramienta de visualización que finalmente se utilice.

Especificaciones de referencia:

- **Infraestructura:** Azure SQL Database (Standard S2) o Databricks SQL Serverless.
- **Uso previsto:** almacenamiento de la capa de servicio (*Gold*) para consulta desde Power BI, Streamlit o Tableau.
- **Inicio estimado:** segunda mitad de febrero de 2027.
- **Periodo presupuestado:** 6 meses.

Concepto	**Costo Mensual (USD)**	**Costo Total 6 Meses (USD)**	**Costo Total (COP aprox.)**
Servicio de Base de Datos Cloud (Azure/AWS) *50 DTU / 2 vCores, Almacenamiento 250 GB*	$ 75.00	$ 450.00	$ 1.800.000 COP

Tabla 3: Estimación presupuestal para la infraestructura de base de datos cloud (capa Gold).

Nota: La estimación en pesos colombianos (COP) utiliza una TRM de referencia de $4,000 COP/USD. El valor final podrá variar de acuerdo con el consumo de almacenamiento, procesamiento y transferencia de datos.

7. Bibliografía

Arteaga Huarancca, P. M., & Mayuri Carlos, A. G. (2026). Ejecución presupuestal en la inversión pública de las municipalidades peruanas: una revisión sistemática. *Santiago*, (168), 1120–1127. https://doi.org/10.22276513

Banker, R. D., Charnes, A., & Cooper, W. W. (1984). Some models for estimating technical and scale inefficiencies in Data Envelopment Analysis. *Management Science*, 30(9), 1078–1092. https://doi.org/10.1287/mnsc.30.9.1078

Benvenuto, M., Notarangelo, L., Viola, C., & Aufiero, C. (2025). The efficiency score as an indicator of the appropriateness of public spending. A pilot study in Italian metropolitan cities. *International Public Management Review*, 25(1), 93–132. https://www.ipmr.net/

Boykin, E., Lofaro, R. J., McCue, C., & Prier, E. (2025). Advancing the practice of public procurement performance measurement: A framework for conceptualizing efficiency and effectiveness. *Public Money & Management*, 45(4), 349–359. https://doi.org/10.1080/09540962.2024.2361832

Eroğlu, B. B., & Taştan, H. (2025). Technical efficiency of Turkish municipalities: Evidence from Data Envelopment Analysis. *Journal of Financial Politic & Economic Reviews / Finans Politik & Ekonomik Yorumlar*, 62(673), 175–217.

Franco Vargas, M. H., Ramírez Brouchoud, M. F., & Chinkousky Giraldo, M. A. (2019). Los controles a la administración pública en Colombia. Una aproximación al control social al presupuesto participativo en Medellín. *Reflexión Política*, 21(41), 50–63. https://doi.org/10.29375/01240781.3320

Kumbhakar, S. C., & Lovell, C. A. K. (2000). *Stochastic frontier analysis*. Cambridge University Press.

Marinas, L., & Prioteasa, E. (2015). Views on the absorption rate of the European Social Fund in Romania. *Review of International Comparative Management / Revista de Management Comparat International*, 16(3), 354–371.

Monsalvo, A. E., Zuluaga-Pardo, C. M., Restrepo-Carmona, J. A., Aguilera-Pua, L., Castaño, J. C., Borda, E. F., Villamil, R. M., García, H. F., & Fletscher, L. (2025). Fiscal management and artificial intelligence as strategies to combat corruption in Colombia. *Information*, 16(11), 998. https://doi.org/10.3390/info16110998

Ojiako, U., Iqbal, M., Dacre, N., Baxter, D., Dong, H., Qazi, A., Chipulu, M., & Al-Mhdawi, M. K. S. (2026). Advancing project success prediction through machine learning-driven models. *Production Planning & Control*. Publicación avanzada en línea. https://doi.org/10.1080/09537287.2026.2676289

Rozo Contreras, D. A. (2020). *Evaluación del cumplimiento del Plan Municipal de Desarrollo de Mutiscua, Norte de Santander* [Trabajo de grado de maestría, Universidad Santo Tomás]. Repositorio Institucional Universidad Santo Tomás.

Sánchez-Chero, J., Sánchez-Chero, M., Bruno-Coveñas, P., & Chero, F. (2026). Uso de ingeniería inversa en minería de datos abiertos en la gestión pública: Revisión bibliográfica. *Revista de Ciencias Sociales*, 32(1), 446–459. https://doi.org/10.31876/rcs.v32i1.41234